

CAHIER DES CHARGES

Projet : Smart Recruitment Data Warehouse (Premier League)

Rôle :	Junior Data Engineer & Analyst
Technologies :	Python (Selenium, Pandas), PostgreSQL, Power BI
Architecture :	Architecture Médaillon (Bronze, Silver, Gold)

1. Contexte du Projet

Dans le football moderne, la cellule de recrutement des grands clubs fait face à une inflation massive des prix des joueurs. Pour optimiser les budgets de transfert, l'analyse des données (Scouting Analytique) est devenue indispensable. Ce projet consiste à mettre en place un ****Data Warehouse complet**** qui centralise les performances des joueurs de la Premier League afin d'identifier des opportunités de recrutement à forte valeur ajoutée et à moindre coût.

2. Problématique Métier

Comment la direction sportive peut-elle filtrer efficacement le marché mondial pour détecter des joueurs performants (High Performance), fiables (Discipline & Disponibilité) et adaptés à un budget restreint avant l'ouverture du mercato ?

3. Objectifs du Système

Fonctionnels :

- **Filtrage Avancé** : Permettre à la direction de filtrer par Poste, Budget et Âge.
- **Analyse de Fiabilité** : Évaluer le risque d'indiscipline (Cartons Rouges/Jaunes) et de blessures.
- **Scouting Prédictif** : Prédire le nombre de buts potentiels pour la saison suivante via un modèle de Machine Learning intégré.

Techniques :

- **Pipeline ETL robuste** : Ingestion via Selenium, transformation et Cleaning avec Pandas.
- **Modélisation Cohérente** : Conception d'un schéma en étoile (Star Schema) dans PostgreSQL.
- **Restitution** : Création d'un Dashboard interactif et dynamique sur Power BI.

4. Spécifications des Données & Pipeline Médaillon

Couche	Source / Format	Traitements Appliqués
Bronze (Raw)	FBref (Scraping live via Selenium)	Extraction brute des statistiques Standard, Shooting et Passing en fonction des matchs
Silver (Clean)	Pandas & Scikit-Learn	Flatten MultiIndex, Drop des doublons, jointure des sources, Enrichissement des données
Gold (Warehouse)	PostgreSQL (Star Schema)	Stockage structuré dans des tables de faits (Fact_Performances) et des dimensions

5. Indicateurs Clés de Performance (KPIs)

- **Performance Score** : Ratio Buts + Passes Décisives par rapport aux minutes jouées.
- **Discipline Risk Score** : Indicateur pondéré basé sur le nombre de cartons reçus.
- **ROI Financier prédictif** : Coût du joueur par rapport à ses buts attendus (Predicted Goals).